

L08

Работа с видеопотоком - детекция объекта внимания и методы трекинга. Часть 1: детекция объекта внимания

ФОС дисциплины «Компьютерное зрение»
DL-3.1, уровень С; основной КИМ: D36

Результаты РПД и КРМ

Извлекать кадры и клипы с временными метками.

-
- Применять покадровую CNN-модель к видеопотоку.
-
- Обрабатывать временные последовательности CNN+RNN и 3D-CNN.
-
- Оценивать качество, задержку и эффективный FPS.
-

Связь с ФОС: Д36 напрямую проверяет frame-wise и clip-wise обработку.

Видео как данные

Видео - упорядоченная последовательность с FPS и временной шкалой.

- Потеря кадров, VFR и декодирование влияют на измерения.
- Клип задается длиной T , шагом окна и стратегией выборки.
-

Связь с ФОС: В README фиксируется форма входного тензора.

Объект внимания

Это объект/событие, определенное прикладной задачей, а не просто движение.

-
- Детектор должен иметь критерий уверенности и пространственный результат.
-
- Контекст сцены и временная устойчивость уменьшают ложные срабатывания.
-

Связь с ФОС: Постановка должна быть сформулирована до выбора модели.

Фоновая модель как baseline

Static/average/MOG2 полезны при статичной камере и движущемся объекте.

-
- Они не распознают класс и ломаются при движении камеры/тенях.
-
- Baseline нужен для сравнения, но не покрывает CNN+RNN/3D CNN.
-

Связь с ФОС: Исходная ЛР6 используется как дополнительный материал.

Покадровый CNN-детектор

Каждый кадр обрабатывается независимо.

-
- Confidence threshold и NMS управляют FP/FN и числом рамок.
-
- Преимущество - простота; недостаток - временное дрожание и одиночные FP.
-

Связь с ФОС: D36 допускает готовую модель.

Временная агрегация

Сглаживание confidence, N-of-M подтверждение, IoU-linking.

- Уменьшает одиночные ошибки, но добавляет задержку и может пропускать короткие события.
- Параметры окна должны измеряться в кадрах и секундах.
-

Связь с ФОС: Обязательная собственная часть Д36.

CNN+RNN

CNN формирует признак каждого кадра; RNN/GRU/LSTM агрегирует

- последовательность.

Вход обычно $V \times T \times C \times H \times W$, после CNN - $V \times T \times D$.

-

Подходит для последовательной причинной обработки и переменной длины.

-

Связь с ФОС: На защите требуется объяснить формы тензоров.

3D-CNN

Свёртка выполняется по времени и пространству.

-
- Модель учит локальные движения и внешний вид совместно.
-
- Вход $V \times C \times T \times H \times W$; вычислительная цена выше покадровой модели.
-

Связь с ФОС: Достаточен инференс готовой r3d/x3d-модели.

Точность и потоковые метрики

TP/FP/FN на размеченном фрагменте; precision/recall.

-
- Latency, throughput/FPS, пропуски кадров и время до подтверждения.
-
- Метрика должна отражать стоимость запоздания и ложной тревоги.
-

Связь с ФОС: Д36 требует качество и производительность.

Ресурсные режимы

CPU-only: короткий ролик, уменьшенное разрешение, готовая легкая модель.



GPU: пакетная обработка клипов и mixed precision.



Задание не должно требовать платного API или конкретной камеры.



Связь с ФОС: Тиражируемость учитывается чек-листом.

Контроль и доказательства

Код чтения, кадры/клипы, две постановки модели.

-
- Видео с предсказаниями и таблица ошибок/FPS.
-
- Сложные эпизоды: blur, occlusion, одиночный false positive.
-
- Объяснение компромисса качество-задержка.
-

Связь с ФОС: КИМ-2.3 и HW08.

Литература и вопросы

Carreira & Zisserman: I3D.



Tran et al.: 3D ConvNets.



Torchvision Video Classification Models.



Вопрос: когда временная модель повышает точность, но ухудшает полезность

• системы?

Связь с ФОС: Ссылки и версии моделей фиксируются.